Считайте что это и есть тест

задачи на вещественные числа (не затрагивая прогу)

1. перечислите все необычные состояния вещественные числа float типа, когда они достигаются. на примере real32, real64
   (a) NaN:sNaN и qNaN (quit NaN, signing NaN)
   (b) +inf, -inf,
   (c) +0, -0
   пример в half precision

$+\inf$	0 11111 00 0000 0000	$-\inf$	1 11111 00 0000 0000
sNaN	0 11111 $\underline{0}$0 0000 0001	qNaN	0 11111 $\underline{1}$0 0000 0000
+0	0 00000 00 0000 0000	-0	1 00000 00 0000 0000

2. заполните табличку числом разрядов

стандарт	размер	бит знака	порядок	мантисса	bias
half precision	16	1	5	10	15
single precision	32	1	8	23	127
double precision	64	1	11	52	
quad precision	128	1	15	112	
extended precision	80	1	15	64	

3. как громкий NaN (sNaN) переделать в тихий NaN (qNaN): Старший бит мантисы поставить на 1
4. что выдаст sqrt(-1.0f) ;;C код - лучший ответ sNaN - так как qNaN ставит только программист по своему усмотрению ответ NaN
5. В каких случаях float может считаться денормализованным - если число $1.0 * 2^{bias}$ пример в половинной точности 2^{-15}, хоть само число ещё вроде можно представить но так как все нули это 0, то мы будем записывать уже денормализованное число, те E=0 а старший бит Мантиссы есть 1 а не 1/2
   ещё раз 2^{-15} будет записано как 0 00000 10 0000 00000 числа меньше также
6. переведите в число единичной точности
   +0: 00000000

   86.125

   (a) $86.125_10 = 1010110.001_2 = 1.010110001_2 * 2^6$,
   (b) bias $= 2^{8-1} - 1 = 127$, $E = 6 + 127 = 133 = 10000101_2$
   (c) итого запись: $0|10000101|01011000100000000000000_2 = 42AC4000_{16}$

   196.75
   приведу способ быстро проверить себя убедившись что числа действительно так хранятся в ассемблере, заодно закинув макросы:

```
include console.inc
include helpful.inc

.data
    pr real4 196.75
.code
Start:
    outbin pr
    newline
    outhex pr
    exit
end Start
```

1/3
вспоминаем как нас научил Алексеев:

$$\frac{1}{3}$$

1	0,
1*2=2, 2 mod 3 = 2	2 div 3 = 0
2*2=4, 4 mod 3 = 1	4 div 3= 1

снова получили в остатке 1 значит мы зациклись получили запись $0.01010101(01)_2 = 1.01(01) * 2^{-2}$
$E = -2 + 127 = 125 = 01111101_2$
получаем: 0|01111101|01010101010101010101010|**101** - необходимо округлить к ближайшему чётному
мантиссу $0/1 \to 0$
ответ: $0\ 0111\ 1101\ 0101\ 0101\ 0101\ 0101\ 0101\ 010_2 = 3EAAAAAA_{16}$

-0 = 80000000_{16}

$20 * 2^{-128} = 1.01_2 * 2^4 * 2^{-128}$
порядок = -124: -124+127=3
ответ: 0 0000 0011 0100 0000 0000 0000 0000 000

7. сложите два числа half precision:
890.5 + 10.5625
окомментируйте все сдвиги поэтапно

переведём числа в биты:
$890.5 = 1.1011110101_2 * 2^9 = 0\ 11000\ 10\ 1111\ 0101_2$ (a)
$10.5625 = 1.0101001_2 * 2^3 = 0\ 10010\ 01\ 0100\ 1000_2$ (b)

разница между экспонентами 11000_2 и $10010_2 = 6$
сдвигаем мантиссу числа (b) на 6 стандарт IEEE-754 требует чтобы операции происходили с большей точностью

1.1011110101000	(a)
0.0000010101001	(b)
1.1100001010001	(a+b)

1.1100001010001 - нормализуем (уже нормализовано экспонента остаётся как у (a))
округляем на лекциях мы рассматривали стандартное банковское к ближайшему чётному
1100001010 0 - первые 10 чисел после точки и 11 число 00 $\to$ 0
получится число: 0 11000 1100001010 = 901

8. решите уравнение считая что числа округление банковское single precision 98.3125+X=98.3125

98.3125 = 1100010.0101=1.1000100101*2^6
его запись будет $0\_10000101\_10001001010000000000000_2$ чтобы число не поменялось нужно прибавить что то маленькое по модулю чтобы после округления оно осталось таким же
несложно понять что искомый X по модулю меньше $0.00000000000000000000001_2 * 2^6$(23 знака после точки) так как иначе мы бы увидели это в мантиссе после сложения
так как округление банковское а последний разряд 0 то при любом исходе округляться будет в меньшую сторону -23+6=-17 $\to$

$$-2^{-17} < X < 2^{-17}$$

НЕРАВЕНСТВА СТРОГИЕ!!

решите это же самое уравнение уже в half precision, сравните результат

98.3125 = 1100010.0101=1.1000100101*2^6
его запись будет 0 10101 1000100101
аналогично несложно понять что искомый X по модулю меньше $0.0000000001_2 * 2^6$(10 знаков после точки), но последний бит $\neq 0 \to$

возможно округление для это нужно чтобы число было больше или равен $0.00000000001_2 * 2^6$(11 знаков после точки) делаем вывод -11+6=-5

$$-2^{-5} < X < 2^{-5}$$

9. достижение наибольшего и наименьшего значения float
   все единицы, но dec Порядок, иначе NaN (qNaN) - min
   все единицы, кроме 1 бита = 0 и dec Порядок, иначе NaN (qNaN) - max

Ниже ответы на следующую часть

задачи на ассемблере

1. Укажите разрядность XMM регистра, сколько их

   128 бит 8 штук

2. Согласено соглашению (cdecl, stdcall) как передаётся вещественное число

   в вершине стека FPU в st0

3. реализовать сложение, вычитание чисел (дополнительно умножение, деление) одинарной и двойной сложности используя SSE2

4. Сложить NaN с любым другим числом

5. Сравнить поведение qNaN и sNaN Если переопределить обработку прерывания то будет видно а так нам незаметно;

6. Приведите операции что в результате дадут (real4 (single precision)):

   (a) +inf
   (b) -inf
   (c) NaN
   (d) +0
   (e) -0

   смотреть код